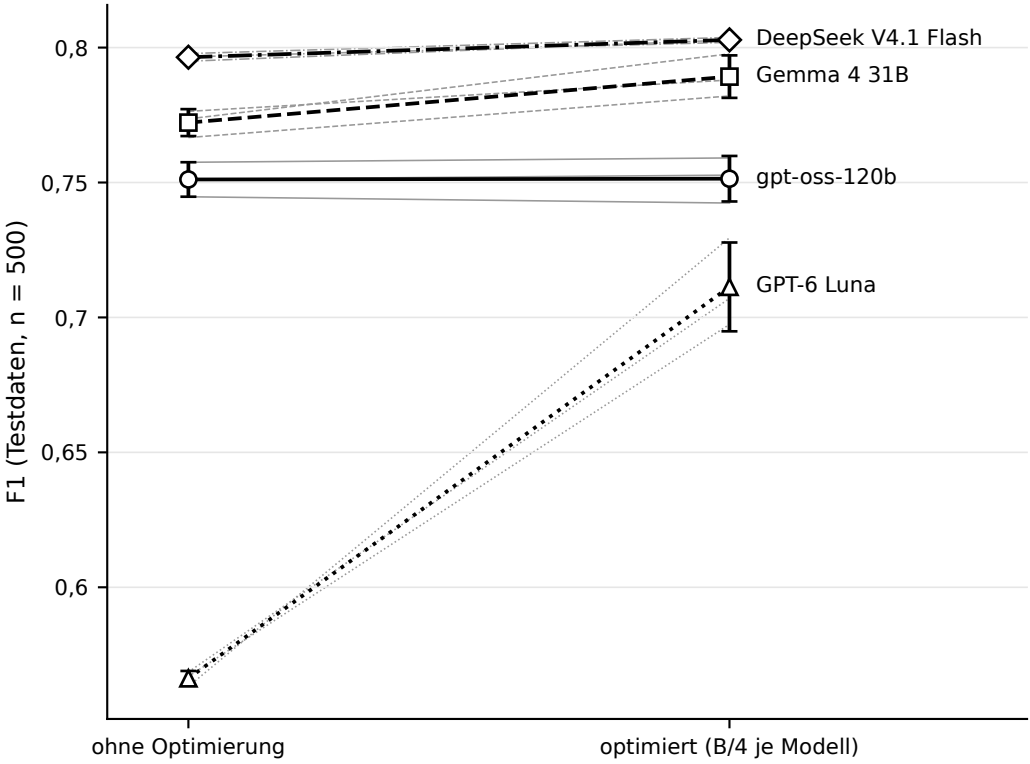
0,8
0,75
0,7
0,65
0,6
F1 (Testdaten, n = 500)
DeepSeek V4.1 Flash
Gemma 4 31B
gpt-oss-120b
GPT-6 Luna
ohne Optimierung
optimiert (B/4 je Modell)