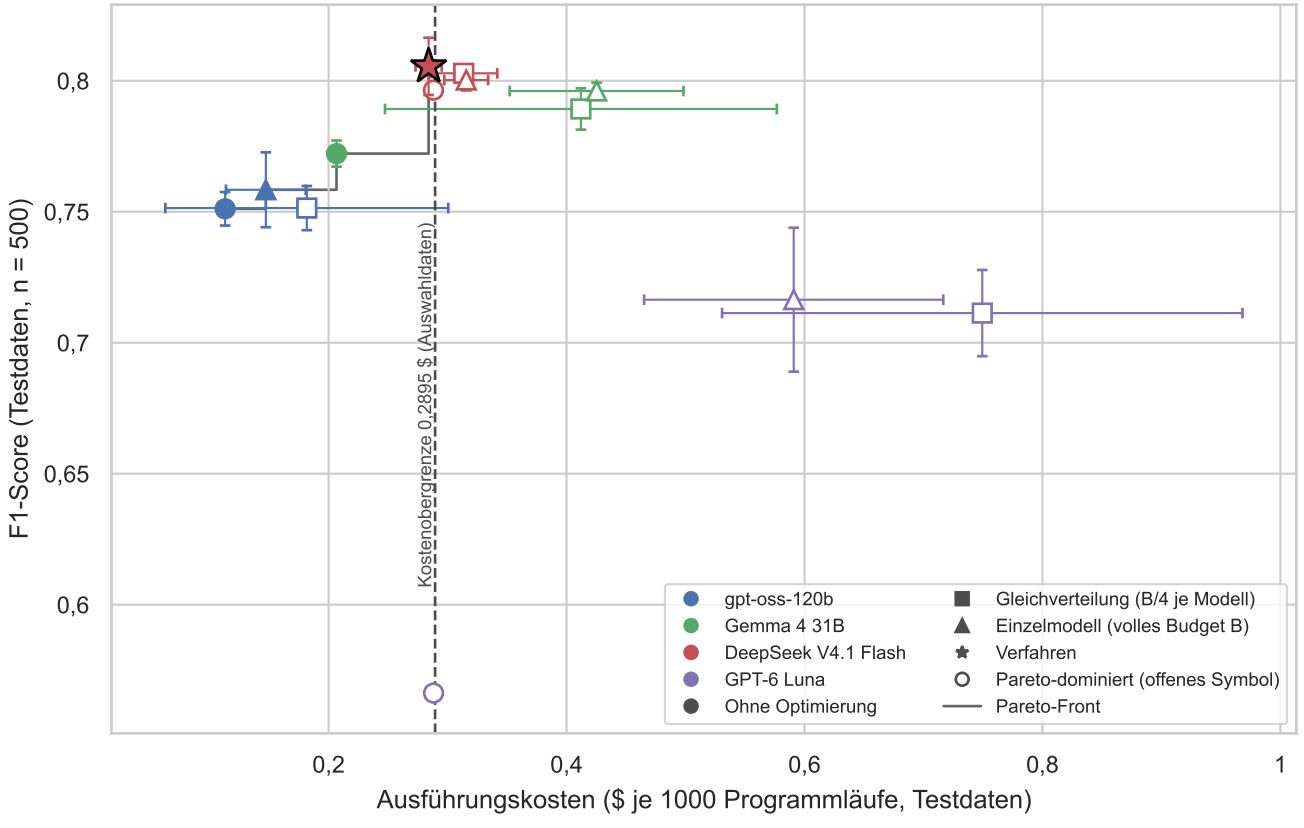
F1-Score (Testdaten, n = 500)
0,8
0,75
0,7
0,65
0,6
0,2
0,4
0,6
0,8
1
Ausführungskosten ($ je 1000 Programmläufe, Testdaten)
Kostenobergrenze 0,2895 $ (Auswahldaten)
gpt-oss-120b
Gemma 4 31B
DeepSeek V4.1 Flash
GPT-6 Luna
Ohne Optimierung
Gleichverteilung (B/4 je Modell)
Einzelmodell (volles Budget B)
Verfahren
Pareto-dominiert (offenes Symbol)
Pareto-Front